CC3084 DATA SCIENCE · PROYECTO 2

Evaluar resúmenes de estudiantes

Reto CommonLit: predecir **content** y **wording** en textos fuente que el modelo nunca vio

Grupo 6 · Jose López · Hugo Barillas · Luis Palacios · Roberto Nájera · Universidad del Valle de Guatemala · 19 de octubre de 2026

El reto: calificar resúmenes de textos nuevos

7.165

resúmenes de estudiantes con nota de un experto

4

textos fuente distintos; el modelo debe funcionar con uno que no vio

2

notas por resumen: **content** (ideas) y **wording** (redacción)

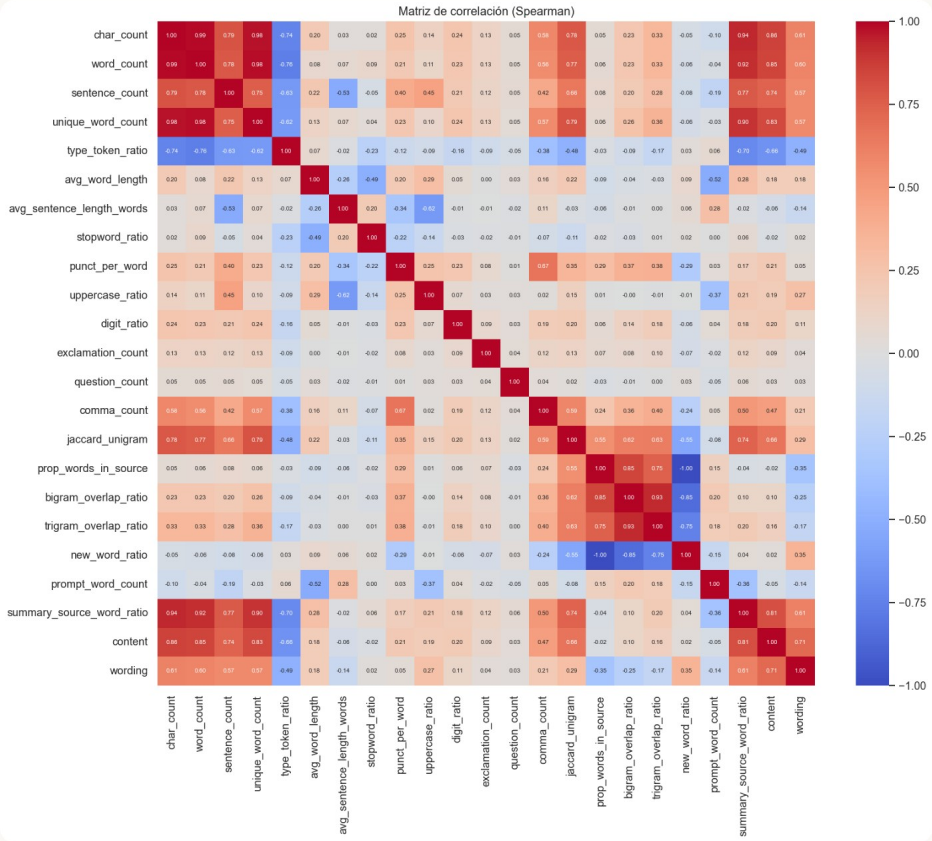
Métrica: **MCRMSE**, el error medio de las dos notas. Menor es mejor.

Validación: dejar un texto fuente fuera

Pliegue	On Tragedy	Egyptian Social Structure	The Third Wave	The Jungle
1	prueba	entrena	entrena	entrena
2	entrena	prueba	entrena	entrena
3	entrena	entrena	prueba	entrena
4	entrena	entrena	entrena	prueba

- Los hiperparámetros se eligen solo con los tres textos de entrenamiento.
- Toda cifra de la presentación es fuera de muestra.

Los datos: la longitud pesa mucho



0,724

MCRMSE de un modelo que solo usa la longitud del resumen

75 %

de la ganancia de LightGBM para **content** viene de caracteres y palabras

Con solo 4 textos, el modelo debe aprender del resumen, no reconocer el texto.

Un hallazgo: el texto fuente se filtra como identificador

Ridge con la longitud de la fuente, error en The Jungle

2,31

Mismo modelo sin ese rasgo

0,52

Con 4 textos, una variable constante por texto identifica al texto. El modelo lineal asigna un desplazamiento a cada uno y extrapola mal al que queda fuera. Se descartaron la longitud de la fuente y la razón resumen/fuente.

Rasgos: de 18 a 33 variables

18 rasgos base

Conteos de caracteres, palabras y oraciones, diversidad léxica, solapamiento de n-gramas y puntuación. Tamaños en logaritmo y banderas de resumen muy corto o muy largo.

+15 rasgos nuevos

Legibilidad (Flesch, Fog, ARI), errores de ortografía, y similitud con el texto fuente y su consigna (TF-IDF y LSA) con cobertura de ideas por oración.

El error baja de 0,592 a 0,567 en Ridge y de 0,546 a 0,524 en LightGBM.

Cinco enfoques comparados

Línea base

Solo la longitud del resumen. Es la referencia que hay que superar.

Ridge

Regresión lineal regularizada sobre los rasgos.

LightGBM

Árboles potenciados, un modelo por nota.

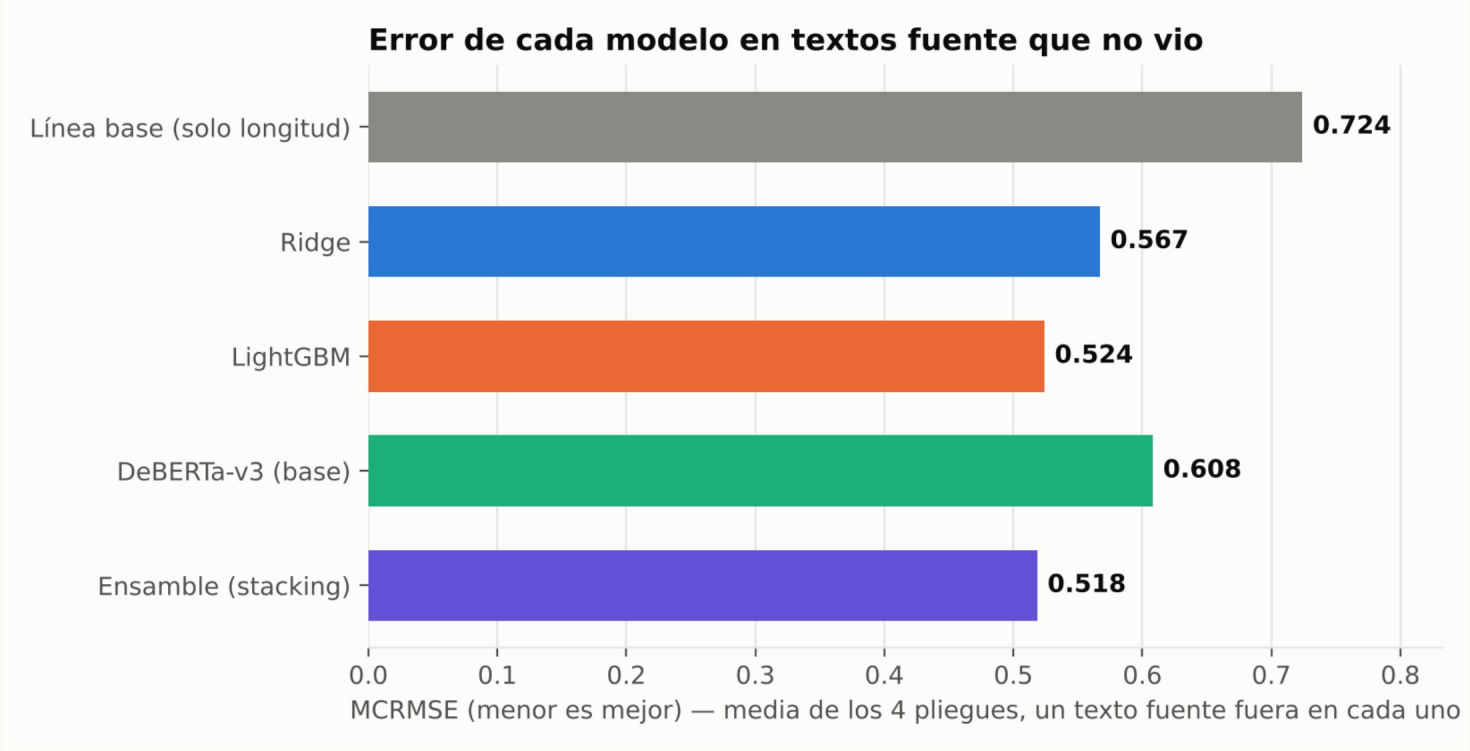
DeBERTa-v3

Ajuste fino de small y base en GPU, 3 épocas fijas, solo el resumen y la consigna.

Ensamble

Ridge con pesos no negativos sobre las predicciones, también fuera de muestra.

Resultados: el ensamble tiene el menor error



0,518 ensamble

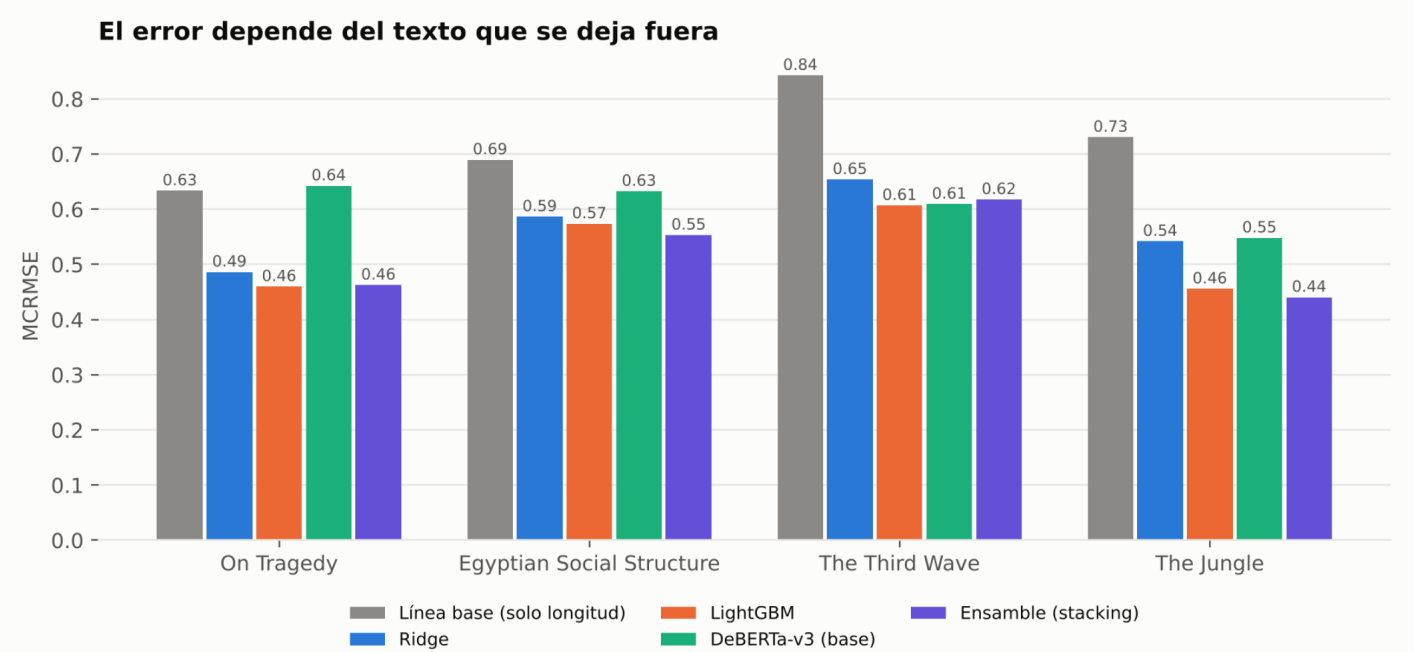
0,524 LightGBM, 33 rasgos

0,567 Ridge, 33 rasgos

0,608 DeBERTa base

0,724 solo longitud

El error cambia mucho según el texto



El texto más difícil para el ensamble es **The Third Wave** (0,618).

Ahí las notas de wording son más altas, y LightGBM las subestima en 0,40.

DeBERTa no superó a LightGBM

Modelo	MCRMSE	RMSE content	RMSE wording
LightGBM, 33 rasgos	0,524	0,448	0,587
DeBERTa-v3 base	0,608	0,484	0,737
DeBERTa-v3 small	0,617	0,481	0,754

- Predice content casi igual de bien, pero wording peor.
- Sobreestima wording en 0,36 puntos en textos nuevos (LightGBM: 0,01).
- Costo: unos 500 s por pliegue en GPU contra menos de 1 s en CPU.

El ensamble: mejora real pero pequeña

Peso de LightGBM

0,55 · 0,62

content · wording

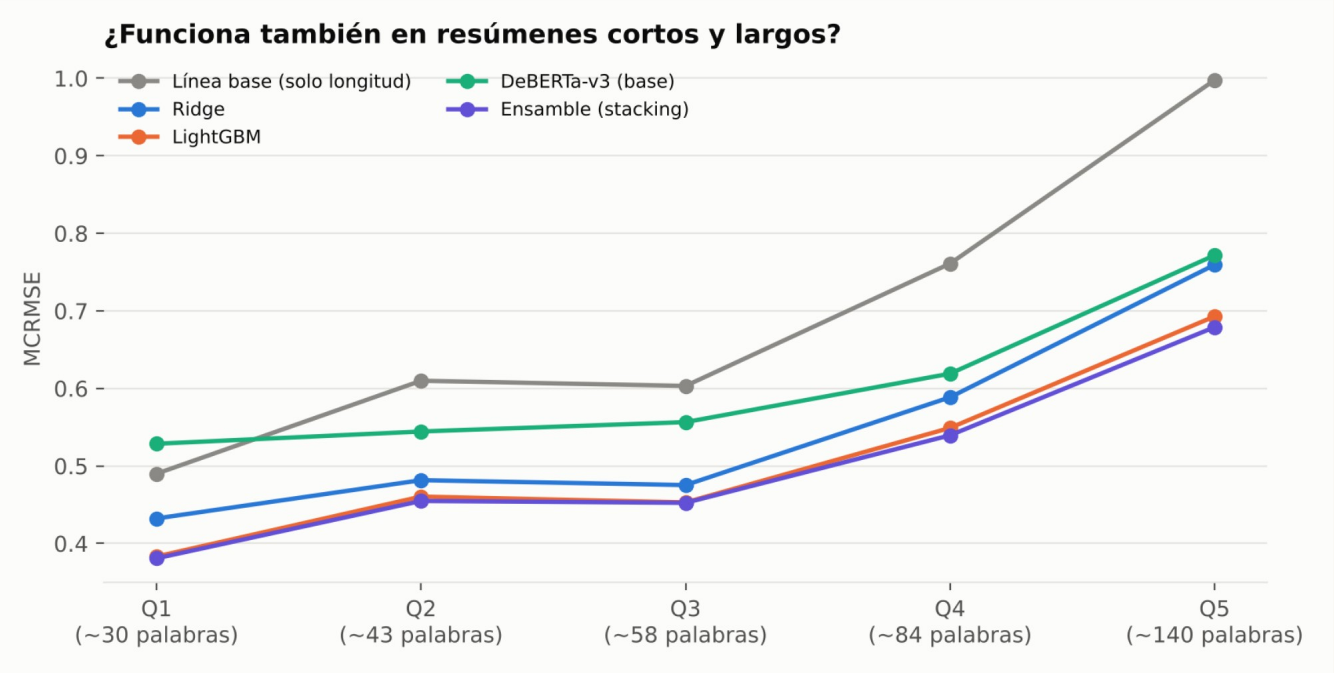
Peso de DeBERTa base

0,28 · 0,36

content · wording

- Sobre LightGBM solo: 0,524 pasa a 0,518. Con cuatro pliegues no es concluyente.
- Sin DeBERTa, el ensamble (0,545) es peor que LightGBM.
- Los errores de ambos en wording se correlacionan en 0,73.

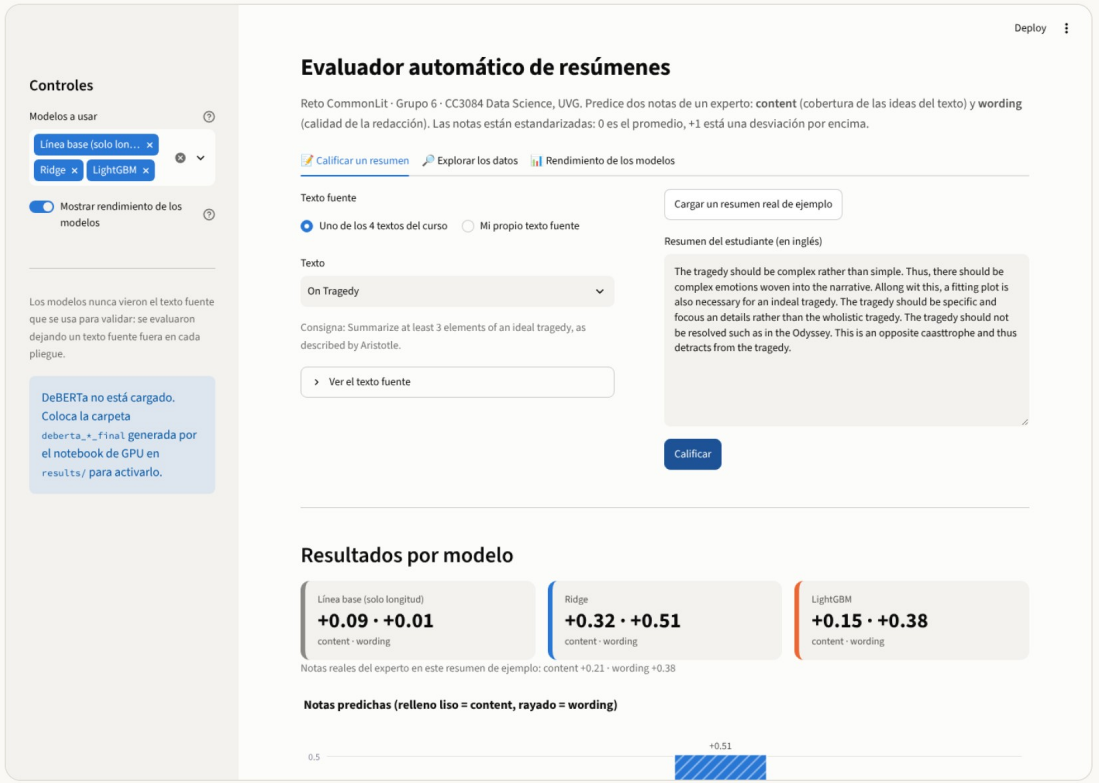
Los resúmenes largos son más difíciles



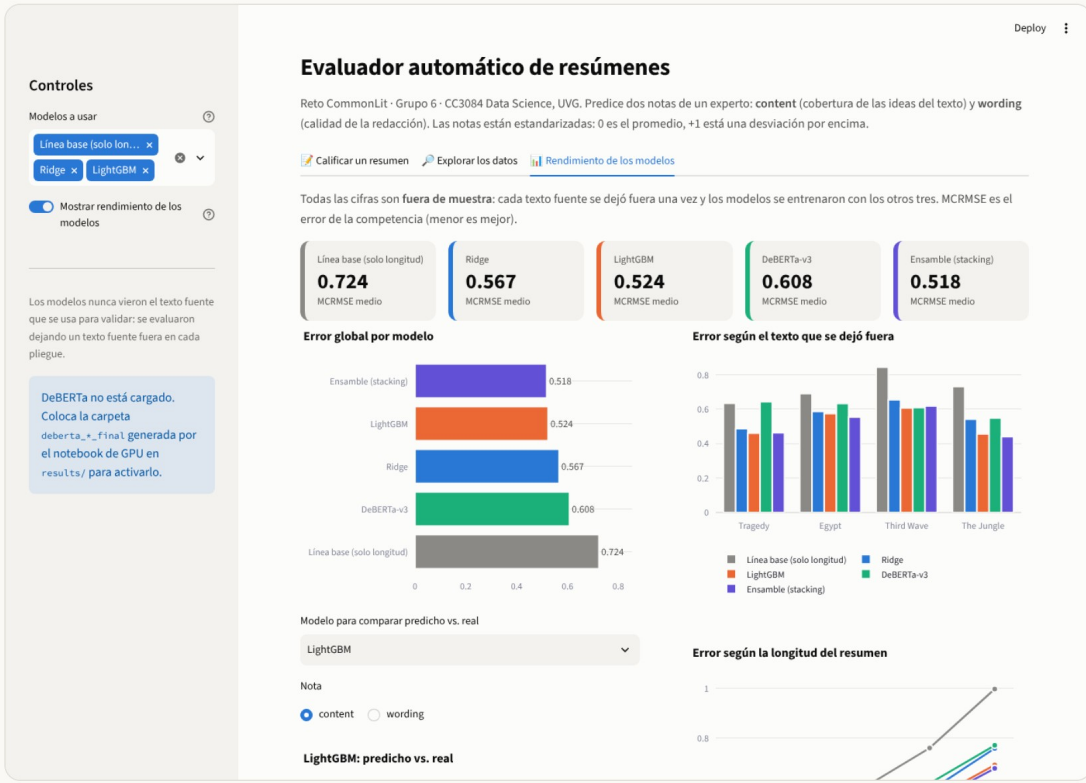
Error del ensamble en el quintil más corto: **0,38**. En el más largo: **0,68**.

Caracteres, palabras y solapamiento de bigramas son los rasgos que más usa LightGBM.

La aplicación



Califica un resumen con cada modelo, por separado o todos.



Gráficas de rendimiento interactivas que se pueden ocultar.

Conclusiones y límites

Lo que encontramos

- El ensamble logra 0,518; LightGBM solo, 0,524.
- Los rasgos nuevos ayudan a Ridge y a LightGBM.
- DeBERTa no supera a LightGBM, pero aporta al ensamble.

Lo que falta

- Solo 4 textos y 1 semilla: diferencias de centésimas no son concluyentes.
- DeBERTa sin el texto fuente en la entrada.
- Probar embeddings de oraciones y varias semillas.